Marketing inteligente en el sector bancario: Análisis integrado de modelos supervisados, no supervisados y por refuerzo para la predicción y segmentación de clientes potenciales

Camilo Andrés López Contreras, Kevin Nicolai García Rodríguez, Juan José Márquez Villareal
Universidad Sergio Arboleda
Ciencias de la computacion e Inteligencia artificial
Bogotá D.C., Colombia

***Resumen*—Este artículo presenta la aplicación integrada de técnicas de Aprendizaje de Máquina supervisado, no supervisado y por refuerzo para apoyar la toma de decisiones de marketing en una entidad bancaria que comercializa depósitos a plazo fijo (CDT). Se utiliza el *Bank Marketing Dataset*, con más de 41 000 registros de campañas telefónicas, 21 variables de cliente, campaña y contexto macroeconómico, y una variable objetivo binaria que indica si el cliente suscribió o no el producto. Primero se construyen y comparan clasificadores (Árboles de Decisión, KNN, Random Forest y SVM) para estimar la probabilidad de suscripción, tratando explícitamente el fuerte desbalance de clases. Después se aplican K-Means y clustering jerárquico para identificar segmentos de clientes con patrones diferenciados de conversión. Finalmente se diseña un agente de Q-Learning que, usando esta información, aprende políticas de contacto más eficientes. El modelo final (Random Forest) alcanza un F1-Score de 0.51 y un ROC-AUC de 0.81, mientras que la segmentación revela un clúster de "alto valor" que representa solo el 3.67 % de la base pero concentra el 63.9 % de las suscripciones. Se discuten implicaciones de negocio, riesgos éticos y una propuesta de despliegue en una plataforma analítica tipo MLOps.**

***Index Terms*—marketing bancario, aprendizaje supervisado, clustering, K-Means, Q-Learning, MLOps.**

I. Introducción y contexto del sector

El sector bancario compite en un entorno cada vez más digitalizado, con clientes informados, múltiples alternativas de inversión y una presión constante por reducir costos. En este contexto, las campañas masivas de telemarketing para vender productos como los depósitos a plazo fijo (CDT) suelen ser poco eficientes: se realizan miles de llamadas con tasas de éxito bajas, generando desgaste comercial y, en algunos casos, molestias al cliente.

La pregunta central de negocio es: *¿a qué clientes conviene contactar, con qué intensidad y en qué momento, para maximizar la probabilidad de suscripción sin disparar los costos ni deteriorar la experiencia del cliente?* Tradicionalmente, esta decisión se tomaba solo con reglas heurísticas (segmentos demográficos, históricos de productos, etc.). Hoy, el crecimiento de los datos y el avance del Aprendizaje de Máquina permiten ir más allá y construir modelos que aprendan estos patrones directamente de la historia de campañas.

En este trabajo nos enfocamos en tres ejes analíticos:

1. **Predicción**: estimar la probabilidad de que un cliente suscriba un CDT, antes de realizar la llamada.
2. **Segmentación**: agrupar clientes según su comportamiento y su probabilidad de convertir, para definir estrategias diferenciadas.
3. **Optimización**: aprender políticas de contacto que equilibren beneficios esperados y costos de campaña en el tiempo.

La combinación de estos ejes da lugar a una solución de *marketing inteligente*: no se trata solo de predecir un "sí" o un "no", sino de entender *por qué* ocurren esos resultados, *qué tipos de clientes* reaccionan mejor y *cómo* priorizar recursos comerciales limitados.

II. Metodología aplicada

II-A. Dataset y comprensión del problema

Se trabajó con el *Bank Marketing Dataset*, que recoge interacciones de campañas telefónicas de una institución bancaria portuguesa. Cada fila representa el resultado de una campaña con un cliente e incluye:

- **Variables del cliente**: edad, profesión (`job`), estado civil, nivel educativo (`education`), presencia de créditos en mora, hipoteca o préstamo personal.
- **Variables de campaña**: tipo de contacto (móvil o teléfono fijo), mes y día de la semana, duración de la llamada, cantidad de contactos en la campaña actual (`campaign`) y número de campañas previas (`previous`).
- **Variables macroeconómicas**: índices de empleo (`emp.var.rate`), precios (`cons.price.idx`), confianza del consumidor (`cons.conf.idx`), tasa Euribor a 3 meses (`euribor3m`) y número de empleados del banco (`nr.employed`).
- **Variable objetivo**: `y`, igual a "yes" si el cliente suscribió el depósito, "no" en caso contrario.

La Figura 1 ilustra algunas distribuciones clave, como la edad, la duración de la llamada y el desbalance de la variable

objetivo, donde se observa que la gran mayoría de registros pertenece a la clase "no suscribió". Esto condiciona todo el análisis posterior.

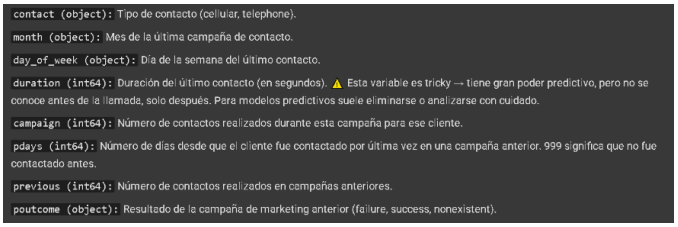


Figura 1. Distribución de variables relevantes y desbalance de la variable objetivo.

II-B. Preprocesamiento e ingeniería de características

El preprocesamiento tuvo un papel crucial para que los modelos reflejaran decisiones realistas de marketing:

II-B1. Eliminación de data leakage: En modelos iniciales se encontró que la variable `duration` aumentaba fuertemente la capacidad predictiva, pero esto es engañoso: la duración de la llamada solo se conoce *después* de haber contactado al cliente. Usar esta variable implicaría decidir a quién llamar con información que no existe en producción. Por ello se decidió eliminar `duration` de todos los modelos que se usarían como referencia.

II-B2. Codificación de variables categóricas: Las variables categóricas se transformaron mediante *one-hot encoding*, generando indicadores binarios para categorías como tipos de trabajo, niveles educativos, meses de campaña o resultados previos. De esta forma, los modelos pueden capturar diferencias entre, por ejemplo, clientes jubilados y empleados, o entre meses típicos de alta o baja demanda.

II-B3. Tratamiento del desbalance de clases: Dado que sólo alrededor del 12 % de los clientes suscriben, un modelo trivial podría acertar más del 80 % de los casos simplemente prediciendo siempre "no". Para evitar esta trampa, se utilizaron varias estrategias:

- Asignar `class_weight` inversamente proporcional a la frecuencia de las clases en Árboles de Decisión y Random Forest.
- Emplear *under-sampling* y SMOTE para ajustar la proporción de clases en el entrenamiento de KNN y SVM.
- Elegir métricas de evaluación que castiguen errores en la clase minoritaria (recall, F1-Score, ROC-AUC), no solo la exactitud global.

II-B4. Normalización y escalado: Para modelos basados en distancia (KNN y SVM), se aplicó `RobustScaler` a las variables numéricas, lo que reduce el impacto de valores atípicos extremos, frecuentes en variables financieras como edad o duración de llamada.

II-B5. Variables derivadas: Se propuso la variable `economic_pressure` como combinación de tasa Euribor y variación del empleo, con la idea de capturar contextos donde, por ejemplo, tasas bajas y empleo inestable pueden incentivar la búsqueda de productos de ahorro.

II-C. Modelos supervisados

Se entrenaron y compararon cinco configuraciones principales:

- **Árbol de decisión 1**: sólo variables numéricas, incluyendo `duration`, usado como línea base (modelo "idealizado" pero no usable en producción).
- **Árbol de decisión 2**: variables numéricas y categóricas codificadas, excluyendo `duration`. Se ajustaron hiperparámetros de profundidad, tamaño de hoja y criterio de división.
- **KNN**: entrenado sobre variables escaladas, probando distintos valores de k y distancias.
- **Random Forest**: modelo *ensemble* de Árboles de Decisión con ajuste de número de árboles, profundidad y tamaños mínimos de hoja.
- **SVM**: con kernel lineal y datos escalados, buscando un margen adecuado entre clases.

La Figura 2 muestra el flujo general del pipeline supervisado, desde la carga de datos hasta la evaluación final.

Modelo	Preprocesamiento	Features Utilizadas	Hiperparámetros Probados	Mejores Hiperparámetros	Justificación de Cambios
Árbol de Decisión 1	Incluyó duration (data leakage)	Solo numéricas: age, duration, campaign, pdays, previous, emp.var.rate, cons.price.idx, cons.conf.idx, euribor3m, nr.employed	criterion="gini", max_depth=5	No se optimizó	Modelo inicial de referencia, pero con data leakage por incluir duration
Árbol de Decisión 2	Eliminó duration	Numéricas + categóricas codificadas: nr.employed, pdays, previous, euribor3m, emp.var.rate, campaign, age, cons.price.idx, cons.conf.idx, poutcome_success, month_mar, month_oct, job_retired, education_university.degree	max_depth: [3,4,5], min_samples_split: [20,50,100], min_samples_leaf: [10,20,30], criterion: ['gini','entropy'], class_weight: [balanced, {0:1, 1:7.88}]	max_depth=5, min_samples_leaf=30, min_samples_split=20, criterion='gini', class_weight={0:1, 1:7.88}	Eliminación de data leakage, inclusión de variables categóricas, optimización de hiperparámetros
KNN	Eliminó duration, escalado RobustScaler	Mismas que Árbol de Decisión 2	n_neighbors: [15,25,50,100], p: [1,2], sampling_strategy: [0.3,0.5,0.7]	n_neighbors=50, p=1 (Manhattan), sampling_strategy=0.3	Prueba de modelo basado en distancias, escalado necesario para KNN
Random Forest	Eliminó duration	Todas las variables (numéricas + categóricas codificadas)	n_estimators: [100,200,300], max_depth: [5,10,15,None], min_samples_leaf: [1,10,30], min_samples_split: [2,10,20], sampling_strategy: [0.3,0.5,0.7]	n_estimators=300, max_depth=15, min_samples_leaf=1, min_samples_split=10, sampling_strategy=0.3	Modelo ensemble más robusto, capaz de capturar relaciones complejas
SVM	Eliminó duration, escalado RobustScaler	Todas las variables (numéricas + categóricas codificadas)	C: loguniform(0.1,1000), kernel: ['linear','rbf'], gamma: ['scale','auto'], sampling_strategy: [0.3,0.5,0.7]	C=5.34, kernel='linear', gamma='scale', sampling_strategy=0.3	Modelo de margen máximo, apropiado para datos de alta dimensión

Figura 2. Pipeline general de entrenamiento y evaluación de modelos supervisados.

II-D. Segmentación no supervisada

Para construir segmentos accionables se decidió utilizar dos enfoques complementarios:

1. **K-Means**, buscando el número de clústeres que mejor separara grupos con comportamientos distintos de campaña y conversión. Se utilizaron principalmente variables como número de contactos, duración (para análisis, no para predicción), contactos previos y variables macroeconómicas.
2. **Clustering jerárquico**, útil para visualizar cómo se van uniendo los clientes y dónde se producen los saltos más grandes en distancia. Se probaron métodos Ward, Average y Complete.

La idea no era solo agrupar por agrupar, sino encontrar segmentos que tuvieran sentido de negocio: por ejemplo, "clientes de alto valor que responden rápido", "clientes prometedores que requieren más explicación", o "base masiva con baja conversión".

II-E. *Diseño del agente de Q-Learning*

Una vez se dispone de:

- un modelo que estima la probabilidad de conversión;
- y una segmentación que describe tipos de clientes;

se propuso un agente de Q-Learning que decide cómo gestionar el contacto en campaña. En lugar de entrar en muchos detalles matemáticos, el enfoque puede resumirse así:

- **Estado**: combinación de (a) probabilidad de suscripción (baja, media, alta), (b) número de contactos realizados y (c) clúster al que pertenece el cliente.
- **Acciones**: no contactar, contactar una vez, o insistir de nuevo (hasta un máximo definido por la política comercial).
- **Recompensa**: ingreso estimado en caso de suscripción, menos el coste de la llamada y una penalización por exceder un número razonable de intentos.

El agente aprende, a partir de simulaciones y resultados históricos, qué combinación de acciones maximiza la recompensa total esperada en el tiempo, es decir, no sólo en una campaña aislada, sino en la relación de largo plazo con el cliente.

III. Resultados y análisis

III-A. *Comparación de modelos supervisados*

La Tabla I presenta las métricas obtenidas por cada modelo en el conjunto de prueba. El énfasis se pone en F1-Score y ROC-AUC, por su capacidad de balancear precisión y recall en un contexto desbalanceado.

Cuadro I
Comparación de modelos supervisados en el conjunto de prueba.

Modelo	Acc.	Prec.	Rec.	F1	ROC-AUC
Dec. Tree 1	0.9139	0.6538	0.5021	0.5680	0.7342
Dec. Tree 2	0.8355	0.3674	0.6372	0.4661	0.7489
KNN	0.8488	0.3725	0.5000	0.4269	0.6965
Random Forest	0.8662	0.4349	0.6264	**0.5134**	**0.8114**
SVM	0.8353	0.3674	0.6372	0.4661	0.7808

El Random Forest se eligió como modelo final porque:

- Mantiene una exactitud razonable sin sacrificar demasiado desempeño global.
- Mejora el recall de la clase positiva, reduciendo la cantidad de suscriptores reales que el modelo pierde.
- Presenta el mayor ROC-AUC, lo que indica buena capacidad de discriminación entre suscriptores y no suscriptores a distintos umbrales.

La Figura 3 muestra la matriz de confusión del Random Forest. Se observan más de 9 800 verdaderos negativos, 872 verdaderos positivos, 1 133 falsos positivos y 520 falsos negativos. Desde un punto de vista de negocio, los falsos negativos representan oportunidades perdidas (clientes que sí habrían comprado), mientras que los falsos positivos representan contactos innecesarios (costo de campaña y posible molestia al cliente).

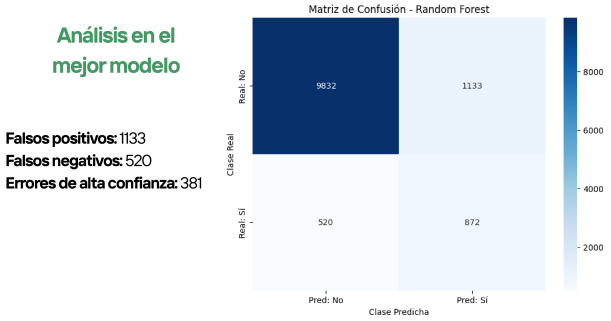


Figura 3. Matriz de confusión del modelo Random Forest.

III-B. *Segmentación con K-Means*

Para seleccionar k se analizaron tres métricas:

- **Método del codo**: la inercia disminuye rápidamente hasta $k = 4$ y luego la mejora marginal es pequeña, indicando un punto natural de corte (Figura 4).
- **Silhouette Score**: el máximo se alcanza en $k = 4$, con un valor alrededor de 0.44 (Figura 5), lo que sugiere clústeres razonablemente compactos.
- **Índice de Dunn**: es más alto para $k = 3$ y $k = 4$, pero el análisis cualitativo favorece $k = 4$ por distinguir mejor segmentos de valor.

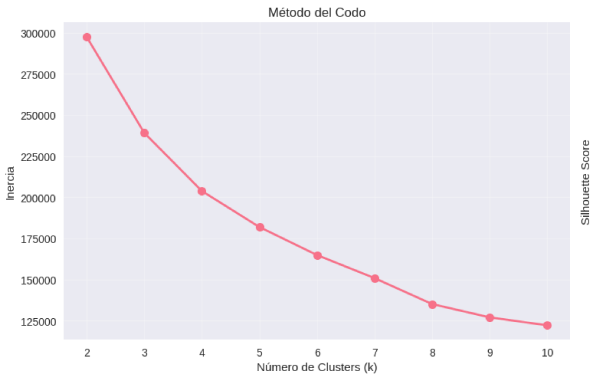


Figura 4. Método del codo para diferentes valores de k en K-Means.

La Tabla II resume los cuatro clústeres encontrados, sus tamaños y tasas de conversión. El clúster de alto valor (3) es pequeño en número, pero concentra la mayoría de suscripciones. El clúster 2 representa clientes prometedores, mientras que el clúster 1 agrupa la base masiva con baja conversión.

Cuadro II
Distribución y tasa de conversión por clúster (K-Means).

Clúster	Clientes	% Base	Tasa conv.
0 – Intermedios	4 108	9.97 %	12.9 %
1 – Base masiva	26 947	65.43 %	4.9 %
2 – Prometedores	8 616	20.92 %	21.2 %
3 – Alto valor	1 512	3.67 %	63.9 %



Figura 5. Silhouette Score promedio para distintos valores de k.

Las Figuras 6 y 7 muestran la distribución de los clústeres en dos dimensiones usando PCA y t-SNE, respectivamente. Visualmente se aprecia una separación clara, lo que valida que los segmentos no son artefactos del algoritmo, sino grupos con diferencias estructurales.

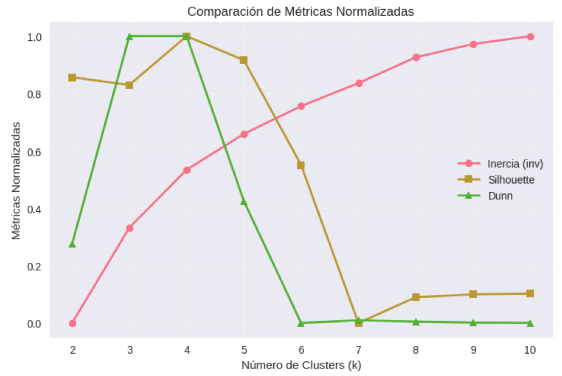


Figura 6. Visualización de clústeres K-Means mediante PCA (dos componentes principales).

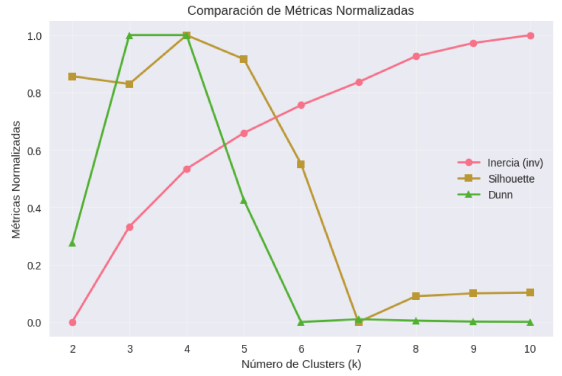


Figura 7. Visualización de clústeres K-Means con t-SNE para $k = 4$.

III-C. Clustering jerárquico

El clustering jerárquico con método Ward confirmó la presencia de cuatro clústeres bien definidos, con tamaños relativamente balanceados. La Figura 8 presenta el dendrograma resultante, donde el corte horizontal indica la altura a la que se decide el número de grupos.

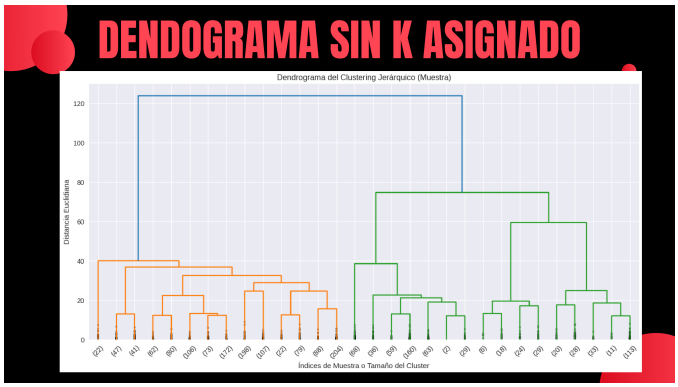


Figura 8. Dendrograma de clustering jerárquico usando el método de Ward.

Este enfoque permitió corroborar que los segmentos obtenidos con K-Means no dependen exclusivamente de la inicialización aleatoria de centroides y que existen saltos naturales en la distancia entre grupos cuando se pasa de 4 a menos clústeres.

III-D. Resultados del agente de Q-Learning

Durante la fase de experimentación con el agente de Q-Learning se observaron varios patrones:

- **Políticas más agresivas** (altos niveles de contacto) se justifican sólo en estados donde la probabilidad de conversión y el valor esperado del cliente son altos (por ejemplo, clúster 3 con probabilidad alta).
- **Políticas conservadoras** (pocos contactos o ninguno) son preferibles en estados de baja probabilidad y en clientes muy contactados previamente, reduciendo el riesgo de saturar al usuario.
- La política aprendida es sensible a los hiperparámetros: un factor de descuento γ muy bajo lleva al agente a decisiones cortoplacistas, mientras que uno muy alto le permite "sacrificar" contactos inmediatos para preservar la relación a futuro.

La Figura 9 ilustra un ejemplo de curva de aprendizaje y el mapa de calor de la tabla Q para uno de los entornos definidos, donde se aprecia cómo ciertos estados favorecen acciones específicas después de suficiente entrenamiento.

IV. Despliegue o propuesta de integración

IV-A. Plataforma de análisis de clientes

Con el fin de acercar estos resultados al usuario de negocio, se diseñó un prototipo de **plataforma de análisis de clientes** que permite:

- Cargar un archivo CSV con la cartera de clientes objetivo.
- Aplicar el preprocesamiento, el modelo supervisado y la asignación de clúster.
- Visualizar métricas agregadas, como distribución de probabilidades de suscripción por segmento.

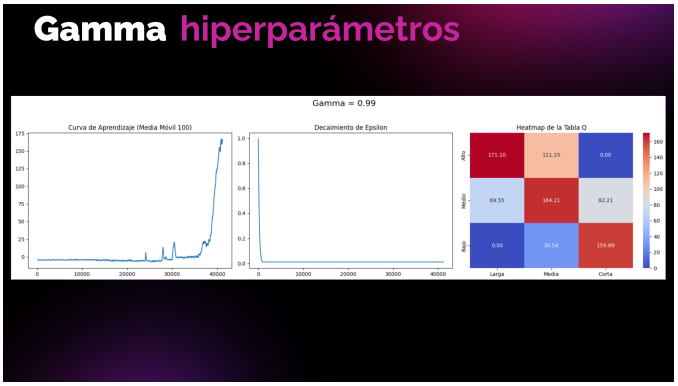


Figura 9. Curva de aprendizaje y mapa de calor de la tabla Q para un conjunto de hiperparámetros.

- Generar listas priorizadas de clientes con recomendaciones de acción (contactar/no contactar, intensidad sugerida).

La Figura 10 muestra la interfaz principal del prototipo.

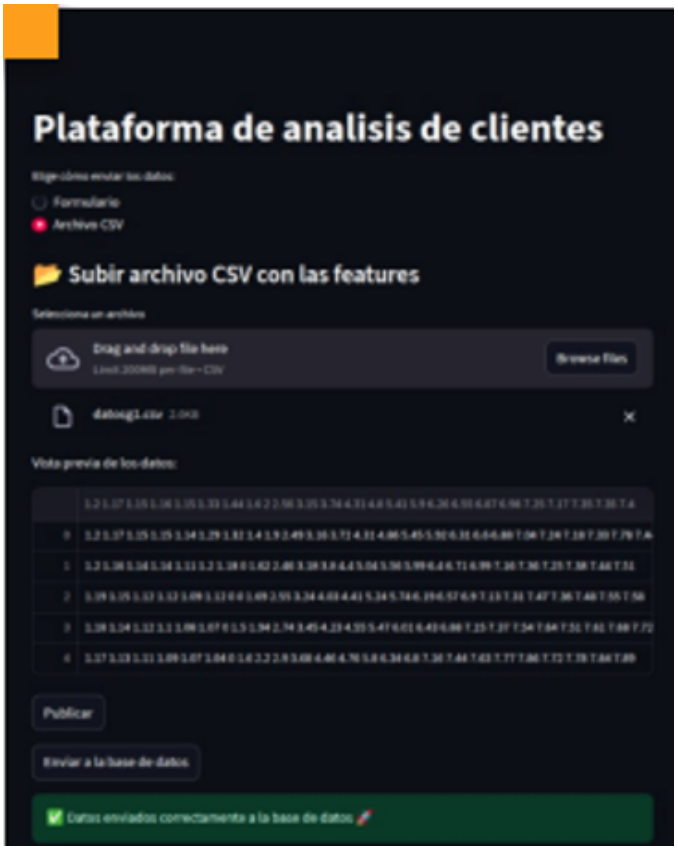


Figura 10. Interfaz de la plataforma de análisis de clientes para el área de marketing.

IV-B. Arquitectura MLOps propuesta

Para una implementación en ambiente bancario real se recomienda:

- Implementar pipelines automáticos de actualización de datos (nuevas campañas, cambios macroeconómicos).
- Versionar modelos y características, de forma que se pueda auditar qué versión generó una predicción en una fecha específica.
- Monitorizar métricas técnicas (latencia, disponibilidad) y de negocio (tasa de conversión, retorno de campaña) de forma continua.
- Incorporar métricas de equidad: por ejemplo, revisar sistemáticamente si el modelo se comporta de manera distinta entre rangos de edad o regiones.

Este enfoque MLOps reduce el riesgo de contar con modelos "congelados" que dejan de representar la realidad del cliente y del entorno económico.

V. Conclusiones y recomendaciones

El proyecto muestra que es posible pasar de una visión puramente operativa de las campañas a una visión analítica integrada:

- El modelo supervisado basado en Random Forest permite priorizar clientes con mayor probabilidad de suscripción, lo que puede traducirse en campañas más eficientes y rentables.
- La segmentación no supervisada identifica segmentos con comportamiento diferenciado, en especial un grupo reducido de alto valor que merece estrategias específicas y un grupo de prometedores donde se justifica invertir más en explicación y acompañamiento.
- El marco de Q-Learning ofrece una herramienta conceptual para decidir cuánto insistir y en qué clientes, incorporando explícitamente el coste de contacto y la visión de largo plazo.

Desde el punto de vista ético y de riesgo, es clave recordar que:

- Los modelos pueden aprender patrones implícitos de discriminación si se apoyan demasiado en variables demográficas o geo-socioeconómicas.
- El contexto macroeconómico cambia; un modelo entrenado en un período de tasas bajas puede dejar de ser válido en un entorno de tasas altas.
- La analítica debe complementar, no reemplazar, el criterio humano y las políticas de cumplimiento normativo del banco.

Referencias

[1] S. Moro, P. Cortez y P. Rita, "A data-driven approach to predict the success of bank telemarketing," *Decision Support Systems*, vol. 62, pp. 22–31, 2014.

[2] R. S. Sutton and A. G. Barto, *Reinforcement Learning: An Introduction*, 2nd ed. MIT Press, 2018.

[3] T. Hastie, R. Tibshirani and J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2nd ed. Springer, 2009.

[4] C. M. Bishop, *Pattern Recognition and Machine Learning*. Springer, 2006.

[5] Streamlit, "Streamlit Documentation." Disponible en: https://docs.streamlit.io. Accedido: 2025.